Python - Analiza danych z modułem PANDAS

www.udemy.com (http://www.udemy.com) (R)

LAB - S10-L001 - Import

- 1. Zaimportuj moduł pandas i numpy nadaj im standardowe aliasy
- 2. Strona https://www.europeandataportal.eu/data/en/dataset/http-ec-europa-eu-eurostat-web-products-datasets-isoc_cimobi_frq (https://www.europeandataportal.eu/data/en/dataset/http-ec-europa-eu-eurostat-web-products-datasets-isoc_cimobi_frq) zawiera informacje na temat wykorzystania mobilnego internetu w EU. Dane w postaci CSV znajdują się pod adresem http://ec.europa.eu/eurostat/estat-navtree-portlet-prod/BulkDownloadListing?file=data/isoc_cimobi_frq.tsv.gz&unzip=true (http://ec.europa.eu/eurostat/estat-navtree-portlet-prod/BulkDownloadListing?file=data/isoc_cimobi_frq.tsv.gz&unzip=true) W kolejnych punktach będziesz pobierać ten plik. Gdyby podany wyżej link nie był już aktualny, to skorzystaj z dołączonego pliku mobile_internet_use_isoc_cimobi_frq.tsv. Znaczenie symboli określających różne rodzaje połączeń znajdziesz pod adresem http://dd.eionet.europa.eu/vocabulary/eurostat/indic_is/view?E_SECINONE=&page=6 (http://dd.eionet.europa.eu/vocabulary/eurostat/indic_is/view?E_SECINONE=&page=6)
- 3. Zadeklaruj zmienną url wskazującą na adres z danymi
- 4. Zaimportuj dane do zmiennej df. Jako separator pól wykorzystaj tabulator
- Do zmiennej df_desc zapisz data frame utworzony jako wynik rozbicia danych z kolumny indic_is,ind_type,unit,time\geo ze względu na przecinek. Skorzystaj z opcji konwertującej wynik do data frame (expand)
- 6. W df_desc zmień nazwy kolumn z 0,1,2,3 na 'indic_is','ind_type',unit','time'
- 7. Korzystając z polecenia join dołacz do df_desc dane z df
- 8. Z df_desc usuń niepotrzebną już kolumnę 'indic_is,ind_type,unit,time\geo'
- 9. Pod adresem https://examples.opendatasoft.com/explore/dataset/world-heritage-unesco-list/export/) znajdują się dane dotyczące obiektów na liście UNESCO. Zaimportuj dane dostępne pod adresem https://examples.opendatasoft.com/explore/dataset/world-heritage-unesco-list/download/?format=json&timezone=Europe/Berlin) Jeżeli plik byłby niedostępny, to skorzystaj z lokalnego pliku world-heritage-unesco-list.json

Rozwiązania:

Poniżej znajdują się propozycje rozwiązań zadań. Prawdopodobnie istnieje wiele dobrych rozwiązań, dlatego jeżeli rozwiązujesz zadania samodzielnie, to najprawdopodobniej zrobisz to inaczej, może nawet lepiej:) Możesz pochwalić się swoimi rozwiązaniami w sekcji Q&A

```
In [1]: import pandas as pd
import numpy as np

In [2]: url = 'http://ec.europa.eu/eurostat/estat-navtree-portlet-prod/BulkDownloadListing?fil
```

Rafal Kraik

```
In [3]: df = pd.read csv(url, delimiter = '\t').head()
           df.head()
 Out[3]:
                       indic is,ind type,unit,time\geo EU28 EU27 EU15 EA BE BG CZ DK DE ... SI SK FI SE
           0
                   I_IHDDAY,CB_EU_FOR,PC_IND,2012
                                                    15
                                                          15
                                                                    12
                                                                       15
                                                                                    22
                                                                                         7 ...
                                                                            : u
                                                                               : u
                I IHDDAY,CB EU FOR,PC IND IU3,2012
                                                    21
                                                         21
                                                                    17
                                                                       19
                                                                                   22
                                                                                        11
                                                                                        60 ...
           2 I IHDDAY,CB EU FOR,PC IND IUHD,2012
                                                    57
                                                         57
                                                                    55
                                                                       48
                                                                            : u
                                                                                                  : u : u
                                                                                       12 ... 3 : u 22
           3
                   I_IHDDAY,CB_EXT_EU,PC_IND,2012
                                                                    13
                                                                                   35
                                                    21
                                                         21
                                                                                       14 ... 5 : u 24
                I IHDDAY,CB EXT EU,PC IND IU3,2012
                                                    28
                                                          28
                                                                    19
           5 rows × 38 columns
In [16]: | pd.read csv("mobile internet use isoc cimobi frq.tsv", delimiter='\t').head()
Out[16]:
                       indic_is,ind_type,unit,time\geo EU28 EU27 EU15 EA BE BG CZ DK DE ... SI SK FI SE
                                                                                                         35
                                                                                                      35
           0
                   I_IHDDAY,CB_EU_FOR,PC_IND,2012
                                                    15
                                                          15
           1
               I_IHDDAY,CB_EU_FOR,PC_IND_IU3,2012
                                                                   17
                                                    21
                                                         21
                                                                       19
                                                                                   22
                                                                                        11 ...
                                                                           : u
                                                                              : u
           2 I_IHDDAY,CB_EU_FOR,PC_IND_IUHD,2012
                                                                    55
                                                    57
                   I_IHDDAY,CB_EXT_EU,PC_IND,2012
                                                    21
                                                                                       12 ... 3 :u 22
                                                                                 : 39 14 ... 5 :u <sup>24</sup>
                I_IHDDAY,CB_EXT_EU,PC_IND_IU3,2012
                                                                    19
                                                    28
                                                          28
           5 rows × 38 columns
 In [5]: df desc = df['indic is,ind type,unit,time\geo'].str.split(',',expand=True)
 In [6]: df desc.head()
 Out[6]:
                                1
                                                   3
                                             2
           0 I IHDDAY CB EU FOR
                                        PC IND 2012
           1 I_IHDDAY CB_EU_FOR
                                    PC_IND_IU3 2012
           2 I_IHDDAY CB_EU_FOR PC_IND_IUHD 2012
            3 I_IHDDAY CB_EXT_EU
                                        PC_IND 2012
            4 I IHDDAY CB EXT EU
                                    PC IND IU3 2012
```

Rafal Kraik 2 z 4

In [7]: df desc.rename({0:'indic is',1:',ind type',2:',unit',3:'time'}, axis=1, inplace=True)

```
In [8]: df desc.head()
 Out[8]:
               indic_is
                          ,ind_type
                                          ,unit time
           0 I IHDDAY CB EU FOR
                                        PC IND 2012
           1 I_IHDDAY CB_EU_FOR
                                    PC_IND_IU3 2012
           2 I_IHDDAY CB_EU_FOR PC_IND_IUHD 2012
           3 I IHDDAY CB EXT EU
                                       PC IND 2012
           4 I_IHDDAY CB_EXT_EU
                                    PC_IND_IU3 2012
 In [9]: df desc = df desc.join(df)
In [10]: df desc.head()
Out[10]:
                                                              indic_is,ind_type,unit,time\geo EU28 EU27 EU15 EA
               indic_is
                          ,ind_type
                                          ,unit time
           0 I_IHDDAY CB_EU_FOR
                                       PC_IND 2012
                                                                                                         12
                                                          I_IHDDAY,CB_EU_FOR,PC_IND,2012
                                                                                          15
                                                                                                15
                                                                                                      16
           1 I_IHDDAY CB_EU_FOR
                                    PC_IND_IU3 2012
                                                      I_IHDDAY,CB_EU_FOR,PC_IND_IU3,2012
                                                                                                21
                                                                                                      21
                                                                                                          17
           2 I IHDDAY CB EU FOR PC IND IUHD 2012 I IHDDAY, CB EU FOR, PC IND IUHD, 2012
                                                                                                57
                                                                                                         55
           3 I_IHDDAY CB_EXT_EU
                                       PC_IND 2012
                                                          I_IHDDAY,CB_EXT_EU,PC_IND,2012
                                                                                                21
                                                                                                      22
                                                                                                         13
           4 I IHDDAY CB EXT EU
                                    PC_IND_IU3 2012
                                                      I_IHDDAY,CB_EXT_EU,PC_IND_IU3,2012
                                                                                                28
                                                                                                      29
                                                                                                         19
           5 rows × 42 columns
In [11]: df.drop('indic is,ind type,unit,time\geo', axis=1, inplace=True)
In [12]:
         df desc.head()
Out[12]:
                                                              indic_is,ind_type,unit,time\geo EU28 EU27 EU15 EA
               indic is
                          ,ind_type
                                          unit time
           0 I IHDDAY CB EU FOR
                                       PC IND 2012
                                                          I IHDDAY,CB EU FOR,PC IND,2012
                                                                                          15
                                                                                                15
                                                                                                      16
                                                                                                         12
           1 I IHDDAY CB EU FOR
                                    PC_IND_IU3 2012
                                                      I_IHDDAY,CB_EU_FOR,PC_IND_IU3,2012
                                                                                          21
                                                                                                21
                                                                                                      21
                                                                                                         17
           2 | IHDDAY CB_EU_FOR PC_IND_IUHD 2012 | IHDDAY,CB_EU_FOR,PC_IND_IUHD,2012
                                                                                                57
                                                                                                         55
           3 I IHDDAY CB EXT EU
                                       PC IND 2012
                                                          I IHDDAY,CB EXT EU,PC IND,2012
                                                                                          21
                                                                                                21
                                                                                                      22
                                                                                                         13
           4 I IHDDAY CB EXT EU
                                    PC IND IU3 2012
                                                      I IHDDAY,CB EXT EU,PC IND IU3,2012
                                                                                          28
                                                                                                28
                                                                                                      29 19
          5 rows × 42 columns
In [13]: url = 'https://examples.opendatasoft.com/explore/dataset/world-heritage-unesco-list/do
```

Rafal Kraik 3 z 4

In [14]: pd.read_json(url).head()

Out[14]:

	datasetid	fields	geometry	record_timestamp	
0	world- heritage- unesco- list	{'category': 'Cultural', 'short_description_en	{'type': 'Point', 'coordinates': [26.69139, 53	2017-10-17T17:34:52+02:00	ff1f5b718ce2ee87f18dfaf20610f257
1	world- heritage- unesco- list	{'category': 'Natural', 'short_description_en'	{'type': 'Point', 'coordinates': [14.996666666	2017-10-17T17:34:52+02:00	0fd1ad38878a73b01bf59ed430446e09
2	world- heritage- unesco- list	{'category': 'Cultural', 'short_description_en	{'type': 'Point', 'coordinates': [-112.91611,	2017-10-17T17:34:52+02:00	fa66a8d51c28871277f1cdd9c0f2d09
3	world- heritage- unesco- list	{'category': 'Cultural', 'short_description_en	{'type': 'Point', 'coordinates': [10.33333, 24	2017-10-17T17:34:52+02:00	b16a410e99f603ef138909f6de916de
4	world- heritage- unesco- list	{'category': 'Natural', 'short_description_en'	{'type': 'Point', 'coordinates': [114.91667, 4	2017-10-17T17:34:52+02:00	bb09d483a4ca7411a334314fb13f1330

In [15]: pd.read_json('world-heritage-unesco-list.json').head()

Out[15]:

	datasetid	fields	geometry	record_timestamp	
0	world- heritage- unesco- list	{'category': 'Cultural', 'short_description_en	{'type': 'Point', 'coordinates': [26.69139, 53	2017-10-17T17:34:52+02:00	ff1f5b718ce2ee87f18dfaf20610f25
1	world- heritage- unesco- list	{'category': 'Natural', 'short_description_en'	{'type': 'Point', 'coordinates': [14.996666666	2017-10-17T17:34:52+02:00	0fd1ad38878a73b01bf59ed430446e09i
2	world- heritage- unesco- list	{'category': 'Cultural', 'short_description_en	{'type': 'Point', 'coordinates': [-112.91611,	2017-10-17T17:34:52+02:00	fa66a8d51c28871277f1cdd9c0f2d09
3	world- heritage- unesco- list	{'category': 'Cultural', 'short_description_en	{'type': 'Point', 'coordinates': [10.33333, 24	2017-10-17T17:34:52+02:00	b16a410e99f603ef138909f6de916de
4	world- heritage- unesco- list	{'category': 'Natural', 'short_description_en'	{'type': 'Point', 'coordinates': [114.91667, 4	2017-10-17T17:34:52+02:00	bb09d483a4ca7411a334314fb13f1330

In []:

Rafal Kraik 4 z 4